

AI 기반 멀티모달 음악 접근성 파이프라인의 설계와
모바일 촉각·시각 음악 경험 시스템 구현Design of an AI-Based Multimodal Music Accessibility Pipeline and
Implementation of a Mobile Tactile-Visual Music Experience System

김상엽*, 김미림**, 김진욱***, 유지아****, 임재범*****, 정필상*****

*Student, Dept. of Computer Science, Soongsil University, Seoul, Korea

**Student, Dept. of Electronic and Information Engineering, Soongsil University, Seoul, Korea

***Student, Dept. of Computer Science, Soongsil University, Seoul, Korea

****Student, Dept. of Data Science, Soongsil University, Seoul, Korea

*****Student, Dept. of Physics, Seoul National University, Seoul, Korea

*****Student, Dept. of Energy Resources Engineering, Soongsil University, Seoul, Korea

[Abstract]

In this paper, we present MUSIC SENSE, a mobile tactile-visual music experience system for deaf and hard-of-hearing (DHH) users based on an AI-driven multimodal music accessibility pipeline. The proposed system integrates source separation, phoneme-level lyrics alignment, pitch extraction, onset analysis, multimodal normalization, and mobile haptic-visual rendering into a single end-to-end workflow. In particular, Demucs is used to separate musical stems, CREPE is applied to vocal pitch estimation, madmom-based onset analysis is used for rhythm extraction, and a phoneme-level lyrics aligner is employed to obtain fine-grained timestamps for singing voice synchronization. The extracted features are transformed into lightweight multimodal metadata and rendered on a mobile client through synchronized visual and tactile cues using Core Haptics. Unlike prior work that relies on dedicated chairs, wearables, or fixed installations, the proposed system is designed for general-purpose mobile devices and scalable platform integration. A small-scale proof-of-concept (PoC) study conducted with a welfare center for children with hearing impairment and qualitative feedback from music therapists suggest that the system can improve rhythm reproduction, assist melody contour following, and reduce manual content-authoring burden in music therapy sessions. The paper also discusses industrial applicability of the proposed pipeline as a metadata-based B2B SDK and therapy-support SaaS model for music, education, and media platforms.

>Key words: Music accessibility, Multimodal interaction, Haptic feedback, Lyrics alignment, Mobile accessibility

✉First Author: Sangyeop Kim, Corresponding Author: Sangyeop Kim

*Sangyeop Kim (yeop@yeop.kr), Dept. of Computer Science, Soongsil University

✉Received: 2026. 00. 00, Revised: 2026. 00. 00, Accepted: 2026. 00. 00.

Copyright © 2026 The Korea Society of Computer and Information
http://www.ksoci.re.kr pISSN:1598-849X | eISSN:2383-9945

[요약]

본 논문에서는 청각장애인, 특히 난청 및 인공와우·보청기 사용자를 위한 모바일 기반 촉각·시각 음악 경험 시스템 MUSIC SENSE를 제안한다. 제안 시스템은 음원 분리, 음소 수준 가사 정렬, 음정·리듬 분석, 멀티모달 정규화, 모바일 햅틱·시각 렌더링을 하나의 AI 기반 파이프라인으로 통합한 것이 특징이다. 구체적으로 Demucs를 이용한 스템 분리, CREPE 기반 보컬 피치 추정, madmom 기반 온셋 분석, 음소 단위 Lyrics Alignment를 통해 음악의 구조 정보를 정밀하게 추출하고, 이를 10 ms 단위의 경량 메타데이터로 변환하여 모바일 디바이스에서 실시간에 가깝게 재생한다. 제안 방식은 기존의 햅틱 의자, 고정형 설치물, 웨어러블 장치 중심 연구와 달리 별도의 전용 장비 없이 범용 모바일 환경에서 동작하며, 플랫폼 연동을 고려한 B2B SDK 구조를 함께 제시한다. 또한 청각장애 아동 대상 소규모 PoC와 음악치료사 인터뷰를 통해 리듬 재현, 멜로디 윤곽 인지, 치료용 콘텐츠 제작 효율 측면에서 유의미한 활용 가능성을 확인하였다. 본 연구는 음악 접근성을 단순 자막 보조 수준이 아닌, 구조적이고 산업적으로 확장 가능한 멀티모달 서비스 문제로 재정의했다는 점에서 의의를 가진다.

>주제어: 음악 접근성, 멀티모달 상호작용, 햅틱 피드백, 가사 정렬, 모바일 접근성

I. 서론

디지털 접근성은 더 이상 복지적 부가 기능에 머무르지 않고, 제품과 서비스의 기본 품질을 구성하는 핵심 요소로 이동하고 있다. 특히 유럽 접근성법(European Accessibility Act, EAA)은 접근성 요구사항을 제품 및 서비스 차원으로 명시하고 있으며, 2025년 6월 28일부터 신규 제품 및 서비스에 적용된다[1]. 이러한 환경 변화는 음악 스트리밍, 교육, 치료, 엔터테인먼트 플랫폼이 청각장애인을 포함한 다양한 사용자의 감각 경험을 구조적으로 재설계해야 함을 의미한다.

그러나 현재의 음악 접근성 기능은 대체로 가사 자막, 간단한 비트 진동, 보조적 시각화 수준에 머물러 있다. 이러한 방식은 음악의 핵심 구성 요소인 리듬, 멜로디, 강세, 다이내믹, 가사 전달 타이밍을 통합적으로 제공하지 못한다. 특히 난청인이나 인공와우 사용자에게 음악은 단지 '들리는가'의 문제가 아니라, 시간적으로 정렬된 구조 정보가 얼마나 명확하게 전달되는가의 문제와 밀접하게 연결된다. 따라서 음악 접근성은 단순 번역이나 보조 디스플레이가 아니라, 오디오 구조를 정밀하게 분석하고 이를 촉각·시각 채널로 재구성하는 멀티모달 정보 처리 문제로 접근할 필요가 있다.

기존 연구는 이러한 문제를 해결하기 위해 여러 유형의 촉각 음악 시스템을 제안해 왔다. Nanayakkara 등의 Haptic Chair는 청각장애인을 대상으로 의자 기반 진동과 시각 디스플레이를 결합해 리듬과 저역 에너지를 전달하였다[2]. 이후 같은 연구진은 이를 언어 훈련 보조 도구로 확장하였다[3]. Karam 등은 Model Human Cochlea를 통해 오디오-촉각 크로스모달 디스플레이 가능성을 제시하였으며[4][5], Hwang 등은 모바일 기기에서 실시간 이중 대역 햅틱 음악 재생기를 구현하였다[6]. Shin 등은 ETRI 기반 Tactile Tone System을 통해 인공와우 사용자의 음정 훈련을 보조하는 웨어러블 시스템을 제안하였다[7]. 이러한 연구들은 각각 중요한 기여를 제공하지만, 전용 장비 의존성, 범용성 부족, 가사 정렬 부재, 실시간 플랫폼 확장성 부족이라는

공통 한계를 가진다.

한편 오디오-촉각 통합의 인지과학적 조건 또한 중요하다. Zampini 등은 오디오-촉각 temporal order judgment에서 숙련 관찰자의 경우 약 40 ms 수준, 비숙련 관찰자의 경우 약 80 ms 수준의 시간 분리가 지각적 구분에 영향을 줄 수 있음을 보고하였다[8]. Karns 등은 선천성 청각장애인의 1차 청각 피질에서 시각·촉각 자극에 대한 재조직화 가능성을 제시하였다[9]. 이는 촉각·시각 자극이 단순 보조 수단이 아니라 실제 음악 지각의 구조를 재구성하는 유효 채널이 될 수 있음을 시사한다.

최근에는 상용 모바일 생태계에서도 음악과 햅틱을 결합한 접근성 기능이 등장하기 시작했으나[18][19], 대개 내부 생성 방식이 폐쇄적이며, 보컬, 리듬, 가사, 구조적 전환을 분리해 이해 가능한 형태로 제공하지는 못한다. 또한 Fletcher는 인공와우 사용자에게 대한 전기-촉각 자극(electro-haptic stimulation)이 멜로디 인식과 피치 변별력을 개선할 수 있음을 체계적으로 리뷰하였으며[20], Zhou 등은 DHH 사용자들의 음악 경험 다양성을 조사하여 기존 시각·촉각 기술이 아직 널리 보급되지 않았으며 보다 맞춤형 접근이 필요함을 밝혔다[21]. 이처럼 AI 기반의 정밀 분석 결과를 플랫폼이 소비 가능한 메타데이터 형태로 변환하고, 이를 범용 모바일 기기에서 동기화 재생하는 아키텍처가 필요하다.

이에 본 연구는 MUSIC SENSE라는 AI 기반 멀티모달 음악 접근성 시스템을 제안한다. 본 연구의 기여는 다음과 같이 정리할 수 있다. 첫째, 음원 분리, 음소 수준 가사 정렬, 보컬 피치 추정, 리듬 온셋 검출, 햅틱·시각 렌더링을 하나의 파이프라인으로 통합하였다. 둘째, 특수 의자나 웨어러블이 아닌 범용 모바일 디바이스를 중심으로 설계하여 실제 서비스 배포 가능성을 높였다. 셋째, 소규모 복지관 PoC와 치료 현장 피드백을 통해 음악 감상뿐 아니라 음악치료·교육 맥락에서의 활용 가능성을 검토하였다. 넷째, 메타데이터 기반 전달 구조를 통해 저작권 부담을 줄이면서도 B2B SDK 형태로 산업적 확장 가능성을 제시하였다.

이후 구성은 다음과 같다. II장에서는 촉각 음악, 오디오-촉각 지각, AI 기반 접근성 시스템 관련 선행연구를 분석한다. III장에서는 전체 시스템 구조를, IV장에서는 제안하는 파이프라인과 수식 기반 매핑 방법을 기술한다. V장에서는 프로토타입 구현과 PoC 결과를 제시하고, VI장에서는 결론과 산업적 확장 가능성을 논의한다.

II. 관련 연구

1. 청각장애인을 위한 촉각 음악 시스템

청각장애인을 위한 촉각 음악 연구는 대체로 고정형 설치 장치, 착용형 장치, 모바일 장치의 세 갈래로 발전해 왔다. Nanayakkara 등은 Haptic Chair를 통해 의자 진동과 시각 디스플레이를 결합하여 Deaf 및 Hard-of-Hearing(DHH) 사용자가 저역 리듬과 음악 구조를 감지하도록 설계하였다[2]. 이 시스템은 청각장애인을 위한 몰입형 음악 경험의 가능성을 보여주었으나, 대형 설치물에 의존하기 때문에 가정, 학교, 복지관, 이동 환경에서의 범용 사용에는 제약이 있었다.

후속 연구에서 Nanayakkara 등은 Haptic Chair를 음성 훈련 보조 도구로 확장하여, 청각장애 사용자의 발화 훈련과 촉각 피드백의 결합 가능성을 제시하였다[3]. Karam 등은 Model Human Cochlea를 제안하고, 음성 및 음악의 정서적 요소를 촉각적으로 전달하는 크로스모달 오디오-촉각 디스플레이를 설계하였다[4][5]. 모바일 기반 연구로는 Hwang 등의 real-time dual-band haptic music player가 대표적이다[6]. 이 연구는 저역과 고역을 분리하여 모바일 장치에서 실시간 햅틱 음악 재생을 수행했으나, 가창의 음정 윤곽이나 가사 전달 타이밍까지 포괄하는 구조적 음악 접근성 시스템으로 확장되지는 않았다.

ETRI의 Tactile Tone System은 보다 직접적으로 음정 훈련 문제를 다룬다. Shin 등은 9개의 진동 모터와 36개 음높이(C3-B5)를 매핑한 웨어러블 장치를 제안하고, 2명의 인공와우 사용자에게 15시간의 보컬 훈련을 제공하여 음정 정확도 향상을 보고하였다[7]. 이 연구는 피치-진동 매핑의 훈련 효과를 보여준다는 점에서 중요하지만, 주된 목표가 노래 훈련이며, 전체 곡 감상 경험, 가사 동기화, 리듬·멜로디·시각 정보의 동시 통합을 제공하지는 않는다.

2. 오디오-촉각 크로스모달 지각과 동기화 정밀도

멀티모달 시스템에서 가장 중요한 기술적 문제 중 하나는 시간 정렬이다. Zampini 등은 오디오-촉각 temporal order judgment 실험을 통해 숙련 관찰자의 경우 약 40 ms, 비숙련 관찰자의 경우 약 80 ms 수준에서 자극 순서 판단 성능이 달라질 수 있음을 보고하였다[8]. 이는 정밀 동기화가 실제 지각 품질에 직접적인 영향을 미친다는 점을 보여준다.

Karns 등은 선천성 청각장애인의 1차 청각 피질에서 시각 및 촉각 입력이 재조직화될 수 있음을 fMRI 기반으로 제시하였다[9]. 이는 청각장애인을 위한 멀티모달 인터페이스가 단순한 대체 출력 채널이 아니라, 실제 감각 처리 구조와 결합될 수 있는 설계 대상임을 의미한다. 또한 Fletcher의 리뷰에 따르면, 인공와우 사용자에게 대한 전기-촉각 자극(electro-haptic stimulation)은 멜로디 인식과 피치 변별력을 유의미하게 개선할 수 있으며, 수십 밀리초의 지연에서도 촉각-청각 통합이 유지될 수 있다[20].

3. AI 기반 음악 접근성 및 포용형 악기 인터페이스

Frid는 Accessible Digital Musical Instruments(ADMI)에 대한 리뷰에서 사용자 맞춤형, 다감각 피드백, 참여적 설계를 포용형 음악 인터페이스의 핵심 원칙으로 정리하였다[10]. 본 연구는 이와 같은 포용형 설계 원칙을 감상 중심 모바일 서비스로 확장한 사례로 볼 수 있다. Zhou 등은 DHH 사용자의 음악 경험 다양성을 조사하며, 현재 보청기가 음악 청취에 최적화되지 않았고 시각·촉각 기술이 널리 보급되지 않아 하위 최적의 음악 경험이 지속됨을 밝혔다[21].

기존 ADMI 연구 다수는 연주 인터페이스, 특수 악기, 웨어러블 피드백 장치에 초점을 맞추는 경향이 있다[10]. Choi 등은 28명의 DHH 사용자를 대상으로 크로스모달 음악 개념을 탐색하고 커스터마이즈하는 시스템을 제안하여 주관적 음악 감상 경험의 향상을 보고하였다[23]. 반면 실제 음악 소비 시장에서는 이미 존재하는 방대한 음원 카탈로그를 어떻게 접근 가능한 형태로 변환할 것인가가 더 중요하다. 따라서 본 연구가

제안하는 인터페이스는 '새로운 인터페이스를 설계하는 문제'와 '기존 음원을 대규모로 재가공해 서비스하는 문제'를 연결한다는 점에서 차별적이다.

4. 연구 공백과 본 연구의 차별성

기존 연구를 종합하면 다음과 같은 공백이 드러난다. 첫째, 많은 시스템이 특수 하드웨어에 의존한다. 둘째, 가사-음소 수준 정렬과 리듬·멜로디 동시 매핑을 함께 제공하는 연구가 드물다. 셋째, 모바일 서비스 및 플랫폼 SDK 수준의 확장 구조를 명시적으로 설계한 사례가 제한적이다. 넷째, 훈련용 시스템과 감상용 시스템이 분절되어 있어 치료·교육·상용 서비스 간 연결이 약하다.

Table 1. Comparison of related works and the proposed system

System	Platform	Core features	Main limitation
Nanayakkara et al. [2]	Haptic chair + display	Low-freq rhythm, immersive tactile	Fixed installation, low portability
Karam et al. [4][5]	Crossmodal display	Audio-to-tactile substitution	Ambient install, hard mass deploy
Hwang et al. [6]	Mobile device	Dual-band haptic playback	No lyrics align, limited structure
Shin et al. [7]	Wearable glove	Pitch-to-vibration mapping	Wearable dep., not full-song
MUSIC SENSE	General mobile	Stem sep., phoneme align, pitch/rhythm, tactile-visual	Small-scale PoC, iOS-centered

III. 시스템 설계

1. 전체 서비스 구조

MUSIC SENSE는 클라우드 분석 계층과 모바일 렌더링 계층으로 구성된 2계층 구조를 가진다. 서버는 음원 입력, 스템 분리, 특징 추출, 가사 정렬, 정규화, 메타데이터 패키징을 담당하며, 클라이언트는 재생 시점에 맞춘 시각 및 촉각 피드백 렌더링을 담당한다. 이 구조의 핵심은 계산 비용이 큰 AI 분석은 서버에서 선행 처리하고, 모바일 단말은 경량 메타데이터를 기준으로 정밀한 재생 동기화만 수행하도록 분리한 데 있다.

분석 결과는 원본 음원 자체가 아니라 시간축 기반 멀티모달 메타데이터로 저장된다. 따라서 서비스 사업자는 음원을 재배포하지 않고도 접근성 레이어를 기존 콘텐츠에 추가할 수 있다. 이는 저작권 위험을 줄이면서 B2B SDK 또는 API 형태의 배포를 가능하게 한다.

2. 서버 측 비동기 분석 파이프라인

서버 파이프라인은 다음의 순서로 작동한다. 먼저 입력 음원에 대해 포맷, 길이, 샘플링 조건을 확인하는 ingest 단계를 수행한다. 이후 Demucs 기반 소스 분리로 보컬, 드럼, 베이스 등 주요 스템을 추출한다[11][12]. 분리된 보컬 스템에는 CREPE 기반 피치 추정과 음소 수준 가사 정렬을 적용하고[13][16], 리듬 중심 스템에는 madmom 기반 onset 분석을 수행한다[14][15]. 이후 각 특징은 정규화, 양자화, 시간축 재샘플링을 거쳐 모바일 친화적 JSON 또는 바이너리 패킷으로 직렬화된다. 서버는 큐 기반 비동기 워커 구조를 사용하므로 대규모 음원 카탈로그

처리에 유리하다.

3. 클라이언트 렌더링 구조

모바일 클라이언트는 세 가지 렌더링 모듈로 구성된다. 첫째, 가사 하이라이트와 위치 변형, 색상·두께 변화를 담당하는 시각 렌더러가 있다. 둘째, 리듬과 음정에 대응하는 촉각 프로파일을 재생하는 Core Haptics 기반 햅틱 렌더러가 있다[19]. 셋째, 오디오 재생 타임라인과 멀티모달 메타데이터를 정렬하는 동기화 모듈이 있다. 클라이언트는 10 ms 단위 시퀀스를 기준으로 현재 프레임의 강도(intensity), 샤프니스(sharpness), 가사 인덱스, 시각 오브젝트 상태를 계산한다.




Fig. 1. MUSIC SENSE System Architecture

Fig. 1. Overall architecture of the proposed MUSIC SENSE pipeline

IV. 제안 방법

1. Demucs 기반 스템 분리

제안하는 파이프라인의 첫 단계는 음악 신호를 구조적으로 분해하는 것이다. 원 신호에는 보컬, 드럼, 베이스, 화성 악기 등이 혼합되어 있으므로, 보컬 피치와 리듬 온셋을 직접 추정하면 간섭이 커질 수 있다. 이를 완화하기 위해 본 연구는 Défossez 등의 Demucs 계열 모델을 사용한다[11][12]. Demucs는 파형 도메인 기반 소스 분리를 수행하며, 후속 연구에서는 hybrid spectrogram-waveform 구조로 확장되었다[12]. 본 연구에서는 분리된 보컬 스템을 가사 정렬 및 피치 분석에, 드럼·리듬 관련 스템을 온셋 분석에 활용하여 후속 특징 추출의 안정성을 높였다.

2. 음소 수준 가사 정렬

가사 정렬은 '어떤 단어가 언제 시작되는가' 수준에 머물면 음악 접근성에서는 충분하지 않다. 실제 노래는 장음, 빠른 발음, 비정형 발성, 멜리스마 등으로 인해 단어 내부의 시간 구조가 크게 달라진다. 특히 한국어 가창의 경우 초성·중성·종성의 3분절 음절 구조로 인해 영어 등 음소 단위 정렬 모델을 그대로 적용하기 어려우며, 공개된 한국어 가창 정렬 데이터셋도 현재로서는 부재하다. 따라서 본 연구는 Schulze-Forster 등의 phoneme-level lyrics alignment 연구를 바탕으로, 음절/음소 수준 정렬을 지원하는 모델을 채택하였다[16]. 음소 정렬 오차는 다음 식 (1)과 같이 정의한다.

$$(식 1) E_{\text{phoneme}} = (1/N) \cdot \sum_i |t_i^{\text{pred}} - t_i^{\text{ref}}|$$

여기서 N 은 정렬된 음소 수, t_i^{pred} 는 모델이 예측한 i 번째 음소의 시작 시각, t_i^{ref} 는 기준 시각을 의미한다. 본 연구는 40

ms 이외의 정렬 정밀도를 설계 목표로 삼되, 이를 보편적 절대 기준으로 단정하지 않고 오디오-촉각 temporal order judgment 문헌에서 보고된 숙련 관찰자 수준의 정밀도 참고값으로 해석하였다[8].

3. 피치 및 리듬 특징 추출

보컬 멜로디 추출에는 CREPE를 적용하였다[13]. CREPE는 파형 입력으로부터 단음(monophonic) 피치를 직접 추정하는 CNN 기반 모델로, 본 연구에서는 Demucs로 분리한 보컬 스템에 적용하여 단일 멜로디 윤곽을 확보하였다. 리듬 특징은 madmom 기반 onset detector를 사용해 추출하였다[14][15]. Onset strength는 식 (2)와 같이 spectral flux 형태로 정의한다.

$$(식 2) \text{Flux}(t) = \sum_k \max(S(k, t) - S(k, t-1), 0)$$

여기서 $S(k, t)$ 는 로그 스케일 또는 정규화된 스펙트로그램의 k 번째 주파수 빈 값을 의미한다. 실제 구현에서는 madmom의 SuperFlux 계열 검출기를 사용하여 vibrato로 인한 오검출을 억제하였다.

4. 멀티모달 정규화와 햅틱 샤프니스 합성

보컬 피치, 리듬 강도, 에너지, 가사 강조도는 단위와 분포가 서로 다르므로, 하나의 출력 채널에 직접 매핑할 수 없다. 따라서 본 연구는 각 특징을 식 (3)과 같이 0~1 범위로 정규화한 후 모바일 렌더링에 사용한다.

$$(식 3) f(x) = (x - x_{\min}) / (x_{\max} - x_{\min})$$

햅틱 샤프니스는 리듬의 선명도와 멜로디 변화량을 동시에 반영하도록 식 (4)와 같이 정의하였다.

$$(식 4) \text{Sharp}_{\text{final}}(t) = \alpha \cdot \text{Flux}(t) + \beta \cdot |df_0(t)/dt|$$

여기서 $\text{Flux}(t)$ 는 정규화된 리듬 온셋 강도, $f_0(t)$ 는 정규화된 보컬 피치 곡선, α 와 β 는 리듬 및 멜로디 변화에 대한 가중치이다. 본 프로토타입에서는 $\alpha=0.6$, $\beta=0.4$ 를 기본값으로 설정하였으며, 보컬 추종 채널과 드럼 채널을 동시 출력할 때 단순 합산이 아닌 가중 결합을 적용하여 과도하게 자극적인 햅틱 패턴이 발생하지 않도록 하였다.

5. 시각·촉각 렌더링 매핑

정규화된 특징은 모바일 환경에서 시각 및 촉각으로 다시 변환된다. 시각 채널에서는 음높이 변화에 따라 가사 위치, 글자 굵기, 오브젝트 크기 또는 색상값을 변화시켜 멜로디의 상·하행을 직관적으로 표현한다. 리듬 이벤트는 박자 경계, 하이라이트, 애니메이션 점멸, 구간 전환으로 표시된다. 촉각 채널에서는 intensity가 강도와 에너지를, sharpness가 음정 또는 리듬의 구조 변화를 표현한다[19]. 본 시스템은 10 ms 단위 진동 프로파일을 생성하여 JSON 또는 동등한 시퀀스 포맷으로 관리한다.




Fig. 2. MUSIC SENSE mobile client prototype screen

V. 구현 및 실험 결과

1. 프로토타입 구현

서버 프로토타입은 Python 기반으로 구현되었으며, Demucs, CREPE, madmom, phoneme-level lyrics alignment 모듈을 통합하였다. 클라이언트 프로토타입은 iOS 중심으로 구현되었고, AVFoundation 기반 오디오 타임라인과 Core Haptics 렌더링을 결합하였다[19]. 현재 버전은 iOS 디바이스에서 시연 가능하며, 향후 Android 및 크로스플랫폼 SDK 패키지로의 확장을 목표로 한다.

내부 데이터 포맷은 10 ms 단위의 시간 인덱스를 기본으로 하며, 각 프레임은 pitch, onset, energy, lyric_index, intensity, sharpness 등의 필드를 포함한다. 로컬 환경(로컬 GPU) 기준 3분 분량의 MP3 파일을 입력했을 때 전체 분석을 마치고 멀티센서리 동기화 데이터(JSON)를 산출하는 데 약 1분 내외가 소요되었다. 고품질 메타데이터 파일 크기는 3분 곡 기준 약 120~180 KB로, 원본 오디오 파일 대비 1% 미만의 용량이며, 보컬 채널과 드럼 채널을 분리 저장함으로써 디바이스 특성이나 사용자 민감도에 따라 출력 강도를 개별 조정할 수 있도록 하였다.

Demucs 모델의 보컬 분리 성능은 MUSDB18 벤치마크 기준 SDR(Signal-to-Distortion Ratio) 약 7.3~8.0 dB 수준으로 보고되어 있으며[11][12], 본 시스템에서도 한국어 대중음악 샘플에 대해 유사한 수준의 보컬 분리 품질을 확인하였다. 이는 후속 피치 추정 및 가사 정렬의 안정성을 확보하는 데 충분한 수준이다.

2. 음소 정렬 및 동기화 검토

프로젝트 내부 검토에서는 가창 음성 정렬 후보로 WhisperX, Whisper-timestamped, phoneme-level lyrics aligner 계열 모델을 비교하였다. 단어 수준 정렬 중심 모델(WhisperX)은 일반 음성에는 효과적이지만, 장음, 빠른 발화, 음절 신장, 멜리스마가 포함된 노래 음성에서는 정렬 오차가 0.08~0.15 s 수준으로 증가하는 문제가 관찰되었다. 반면 Lyrics Align 계열 방식은 오디오-텍스트 유사도 행렬과 DTW 기반 정렬 경로를 이용하여 노래 음성의 비선형 시간 구조를 더 안정적으로 추적하였다. 내부 비교 10곡 샘플에서 Lyrics Align 계열의 평균 정렬 오차는 약 0.04 s(40 ms)로, WhisperX 대비 약 50~70% 낮은 오차를

보였다. 다만 이 결과는 아직 대규모 공개 벤치마크가 아니라 내부 비교에 해당하므로, 향후 MIREX Lyrics-to-Audio Alignment 등 공인 벤치마크와 한국어 가창 데이터셋을 대상으로 정량 평가를 수행할 필요가 있다.

3. PoC 설계

PoC는 청각장애 아동을 지원하는 복지기관 협력 하에 수행되었으며, 총 3명의 아동이 참여하였다. 참여자는 인공와우 착용 2명과 보청기 착용 1명으로 구성되었고, 연령대는 7세에서 10세였다. 평가 과제는 리듬 중심 과제와 노래 따라 부르기 과제로 구성하였다. 리듬 과제는 Gordon PMMA 계열 검사 도구를 참고하여 구성하였으며[17], 노래 따라 부르기 과제는 치료사의 피아노 반주 기반 조건과 MUSIC SENSE 보조 조건을 비교하는 방식으로 진행되었다. PoC에 활용된 대표 콘텐츠는 복지관 교육에 실제 사용 중인 '우리의 소원은 통일'이었다.

Table 2. PoC protocol

Item	Description
Participants	3 children with hearing impairment
P1	Age 8, bilateral CI (3 yrs use), PTA: 95 dB HL
P2	Age 10, unilateral CI+HA (5 yrs), PTA: 85 dB HL
P3	Age 7, bilateral HA, aud. neuropathy, PTA: 70 dB HL
Task 1	Rhythm perception/reproduction (PMMA-like)
Task 2	Sing-along: therapist vs. MUSIC SENSE
Observation metrics	Rhythm match, contour, attention, feedback
Study type	Small-scale observational PoC

4. PoC 결과

PoC 수준에서 관찰된 핵심 결과는 다음과 같다. 첫째, 원곡 대비 리듬 재현 정확도가 baseline 조건 대비 최대 37% 향상되는 경향이 관찰되었다(P1: +37%, P2: +28%, P3: +19%). 특히 단순 청취 또는 피아노 반주 기반 조건보다, 촉각과 시각이 동시에 제공되는 조건에서 박자 경계 인식과 반복 패턴 모방이 더 안정적으로 나타났다.

둘째, 멜로디 윤곽을 따라가는 과제에서는 음정 정확도가 최대 22% 향상되었으나, 모든 참여자에게 동일한 수준의 향상이 나타난 것은 아니었다. 고저 방향을 시각적으로 보조받는 조건에서 상·하행 구분의 혼동이 줄어드는 사례가 관찰되었다. 이는 최근 Siedenburger 등이 보고한 진동촉각 음악 노출이 인공와우 사용자의 청력 검사 성능을 유의미하게 향상시킨다는 결과와도 방향이 일치한다[22].

셋째, 음악치료사 피드백에 따르면, 기존에는 스케치북과 스티커를 이용한 수작업 교육 자료 제작에 음원당 평균 2시간 이상이 소요되었으나, MUSIC SENSE는 메타데이터 기반 자동 생성물을 활용해 이 준비 부담을 크게 줄일 수 있었다. 이는 접근성 기술이 사용자 경험뿐 아니라 콘텐츠 제작 워크플로우 자체를 효율화할 수 있음을 의미한다.

넷째, 현재 복지관에서 실제 음악교육 콘텐츠 생성에 시범적으로 활용되고 있다는 점은, 본 시스템이 단순 데모를 넘어 초기 현장 적합성을 확보했음을 보여준다.

Table 3. Observed trends in the PoC

Evaluation area	Baseline	MUSIC SENSE	Observed tendency
Rhythm reproduction	Auditory cue or therapist	Tactile + visual cue	Improved beat matching
Melody contour following	Limited pitch support	Visual pitch + tactile rhythm	Reduced confusion
Attention/persistence	Variable engagement	Multi-sensory cue	More stable participation
Content authoring	Manual paper/sticker prep	Auto metadata generation	Reduced prep burden

5. 논의

본 연구는 기술 구현과 현장 PoC를 동시에 수행했다는 점에서 실용적 의미가 있으나, 몇 가지 한계를 가진다. 첫째, 현재 프로토타입은 iOS 중심이며, 디바이스별 진동 모터 편차에 대한 정교한 보정이 아직 충분히 반영되지 않았다. 둘째, PoC 표본이 매우 작아 통계적 검증보다는 설계 타당성 수준의 해석에 머물러야 한다. 셋째, 정렬 정확도 0.04 s 수준의 결과는 내부 비교 예시에 기반한 것이므로, 공인된 데이터셋 기반 평가로 확장될 필요가 있다. 넷째, 개인별 촉각 민감도와 청각 보조장치 특성이 다르므로, 향후에는 사용자 적응형 매핑과 캘리브레이션 절차가 추가되어야 한다.

VI. 결론 및 산업적 확장 가능성

본 논문은 청각장애인을 위한 AI 기반 멀티모달 음악 접근성 시스템 MUSIC SENSE를 제안하고, 그 설계, 구현, PoC 결과를 제시하였다. 제안 시스템은 Demucs 기반 스템 분리, CREPE 기반 피치 추정, madmom 기반 온셋 분석, 음소 수준 가사 정렬, 멀티모달 정규화, 모바일 Core Haptics 렌더링을 하나의 파이프라인으로 통합하였다. 이를 통해 음악을 단순히 '진동으로 치환'하는 수준이 아니라, 리듬·멜로디·가사 타이밍·강조 구조를 함께 제시하는 접근성 경험으로 확장하였다.

학술적으로 본 연구는 세 가지 점에서 의미가 있다. 첫째, 청각장애인을 위한 음악 접근성 문제를 전용 장비 중심 연구에서 범용 모바일 환경 문제로 전환하였다. 둘째, 오디오·촉각 시간 정합성을 인지과학 문헌과 연결하여, 음소 수준 정렬의 필요성을 구조적으로 제시하였다. 셋째, 감상, 교육, 치료, 플랫폼 배포를 하나의 메타데이터 파이프라인으로 통합함으로써, 접근성 기술의 서비스화 가능성을 구체적으로 보여주었다.

산업적 측면에서 MUSIC SENSE는 B2B SDK 모델과 치료 지원 SaaS 모델로 확장 가능하다. 플랫폼 사업자는 기존 음악 재생 엔진 위에 메타데이터 기반 접근성 레이어를 추가함으로써 초기 개발 비용을 크게 줄일 수 있다. 또한 원본 음원을 재배포하지 않고도 접근성 기능을 제공할 수 있으므로, 저작권 관리 측면에서도 유리하다. 접근성 규제 강화 역시 본 시스템의 확장성을 뒷받침한다. EAA는 2025년 6월 28일부터 신규 제품 및 서비스에 적용되며[1], 접근성 기능은 향후 글로벌 서비스 사업자에게 선택이 아닌 기본 요건이 될 가능성이 높다.

향후 연구에서는 Android 및 웨어러블 디바이스 확장, 사용자별 촉각 민감도 기반 개인화, 더 큰 규모의 한국어 가사 정렬 평가, 다양한 장르 및 스트리밍 환경 실험, 그리고 생성형

AI를 활용한 자동 설명·수어·그래픽 변환 계층 추가가 필요하다. 이러한 후속 연구가 축적된다면, MUSIC SENSE는 단일 앱 수준을 넘어 음악 접근성 인프라로 발전할 수 있을 것이다.

ACKNOWLEDGEMENT

This work was supported by the SK Telecom's FLY AI Challenger program, conducted in collaboration with the Ministry of Employment and Labor and the Korean Skills Quality Authority as part of the 2025 K-Digital Training.

REFERENCES

- [1] European Parliament and Council of the European Union, "Directive (EU) 2019/882 of 17 April 2019 on the accessibility requirements for products and services," Official Journal of the European Union, 2019.
- [2] S. C. Nanayakkara, E. A. Taylor, L. Wyse, and S. H. Ong, "An Enhanced Musical Experience for the Deaf: Design and Evaluation of a Music Display and a Haptic Chair," in Proc. SIGCHI Conf. Human Factors in Computing Systems, pp. 337-346, 2009. DOI: 10.1145/1518701.1518756
- [3] S. Nanayakkara, L. Wyse, and E. A. Taylor, "The Haptic Chair as a Speech Training Aid for the Deaf," in Proc. 24th Australian Computer-Human Interaction Conference, pp. 405-410, 2012. DOI: 10.1145/2414536.2414600
- [4] M. Karam, F. Russo, C. Branje, E. Price, and D. Fels, "Towards a Model Human Cochlea: Sensory Substitution for Crossmodal Audio-Tactile Displays," in Proc. Graphics Interface, pp. 267-274, 2008.
- [5] M. Karam, F. A. Russo, and D. I. Fels, "Designing the Model Human Cochlea: An Ambient Crossmodal Audio-Tactile Display," IEEE Transactions on Haptics, vol. 2, no. 3, pp. 160-169, 2009. DOI: 10.1109/TOH.2009.32
- [6] I. Hwang, H. Lee, and S. Choi, "Real-time dual-band haptic music player for mobile devices," IEEE Transactions on Haptics, vol. 6, no. 3, 2013. DOI: 10.1109/TOH.2013.7
- [7] S. Shin, C. Oh, and H. Shin, "Tactile Tone System: A Wearable Device to Assist Accuracy of Vocal Pitch in Cochlear Implant Users," in Proc. 22nd Int'l ACM SIGACCESS Conf. on Computers and Accessibility, Article 61, 2020. DOI: 10.1145/3373625.3418008
- [8] M. Zampini, D. I. Shore, and C. Spence, "Audiotactile temporal order judgments," Acta Psychologica, vol. 118, no. 3, pp. 277-291, 2005.
- [9] C. M. Karns, M. W. Dow, and H. J. Neville, "Altered Cross-Modal Processing in the Primary Auditory Cortex of Congenitally Deaf Adults," Journal of Neuroscience, vol. 32, no. 28, pp. 9626-9638, 2012.
- [10] E. Frid, "Accessible Digital Musical Instruments—A Review of Musical Interfaces in Inclusive Music Practice," Multimodal Technologies and Interaction, vol. 3, no. 3, p. 57, 2019. DOI: 10.3390/mti3030057
- [11] A. Défossez, N. Usunier, L. Bottou, and F. Bach, "Music Source Separation in the Waveform Domain," arXiv:1911.13254, 2019.
- [12] A. Défossez, "Hybrid Spectrogram and Waveform Source Separation," arXiv:2111.03600, 2021.
- [13] J. W. Kim, J. Salamon, P. Li, and J. P. Bello, "CREPE: A Convolutional Representation for Pitch Estimation," in Proc. IEEE Int'l Conf. Acoustics, Speech and Signal Processing (ICASSP), pp. 161-165, 2018. DOI: 10.1109/ICASSP.2018.8461329
- [14] S. Böck and G. Widmer, "Maximum Filter Vibrato Suppression for Onset Detection," in Proc. 16th Int'l Conference on Digital Audio

Effects (DAFx), 2013.

- [15] S. Böck, F. Korzeniowski, J. Schlüter, F. Krebs, and G. Widmer, "madmom: a new Python audio and music signal processing library," arXiv:1605.07008, 2016.
 - [16] K. Schulze-Forster, C. S. J. Doire, G. Richard, and R. Badeau, "Phoneme Level Lyrics Alignment and Text-Informed Singing Voice Separation," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 29, pp. 2382-2395, 2021. DOI: 10.1109/TASLP.2021.3091817
 - [17] E. E. Gordon, *Primary Measures of Music Audiation*. Chicago, IL, USA: GIA Publications, 2004.
 - [18] Apple Inc., "Use Music Haptics on your iPhone," Apple Support, 2024.
 - [19] Apple Inc., "Core Haptics," Apple Developer Documentation, 2024.
 - [20] M. D. Fletcher, "Can Haptic Stimulation Enhance Music Perception in Hearing-Impaired Listeners?," *Frontiers in Neuroscience*, vol. 15, 2021. DOI: 10.3389/fnins.2021.723877
 - [21] K. Z. Zhou, W. Peng, Y. Liu, and R. F. Adler, "Exploring the Diversity of Music Experiences for Deaf and Hard of Hearing Individuals," *ACM Transactions on Computer-Human Interaction*, 2025. DOI: 10.1145/3710976
 - [22] A. Delnevo et al., "Exposure to vibrotactile music improves audiometric performances in cochlear implant users," *Scientific Reports*, vol. 15, 2025. DOI: 10.1038/s41598-025-02946-4
 - [23] Y. Choi, J. Jeon, Y. Noh, C. Lee, and J.-H. Hong, "A Way for Deaf and Hard of Hearing People to Enjoy Music by Exploring and Customizing Cross-modal Music Concepts," in *Proc. CHI 2024*, 2024. DOI: 10.1145/3613904.3642665
-